

24-1 DSL 정규 세션

기초과제 1 통계적 사고



- ☑ 본 과제는 「통계학입문」, 「통계방법론」, 「선형대수」 및 「수리통계학(1)」 일부에 상응하는 내용의 복습을 돕기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트(👉)를 적극 활용하시고 학회원 간 토론, Slack 의 질의응답을 활용하시어 해결해주시시오. 단, 답안 표절은 금지합니다.
- ☑ 서술형 문제는 ✍, 코딩 문제는 © 으로 표기가 되어 있습니다. 각 문제에서 요구하는 방법에 맞게 해결하며, 서술형 문제들은 따로 작성하시어 pdf 로 제출해주시고 코드 문제들은 ipynb 파일에 답안을 작성하시어 제출해주시시오.
- ☑ 7/25 (목) 23 시 59 분까지 Github 에 PDF 파일과 ipynb 파일을 모두 제출해주시시오. Github 에 제출하는 방법을 모르다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 활용해주시오.
- ☑ 참고 도서 :
통계학입문(3 판, 강상욱 외), Introduction to Mathematical Statistics(8 판, Hogg et.al.)

문제 1 Central Limit Theorem

중심극한정리는 확률변수의 합 형태 (Sum of Random Variables) 의 극한분포를 손쉽게 구할 수 있도록 해 주기에 통계학에서 가장 자주 사용하는 정리입니다. 이 문제에서는 중심극한정리의 정의와 그 활용에 대해 짚어보겠습니다.

1-1 ✍ : 중심극한정리(Central Limit Theorem)의 정의를 서술하시오.

- 👉 통계학입문 (3 판) 7 장 참고
- 👉 Hogg(8 판) 4 장 2 절, 5 장 3 절 참고

집단 크기가 커질수록 집단 분포가 원래 형태 상관없이 정규분포로 갈아진다

1-2 ✍ : 중심극한정리가 통계적 추론 중 "구간추정"에서 어떻게 활용되는지 서술하시오.

- 👉 Hogg(8 판) 4 장 2 절

표본량이 충분히 커지면, 신뢰구간은 정규분포로 추정할 수가 있는
장점을 가지고 있다.

문제 2 Linear Algebra

선형대수학은 머신러닝을 위한 수학 중에서 가장 중요한 요소 중 하나이며, 이 중에서 가장 중요한 것 중에서 하나는 바로 SVD (Singular Value Decomposition, 특이값 분해) 입니다. 이것을 알기 위해서 고유값과 고유벡터를 활용한 Diagonalization 에 대해서 먼저 알아본 후, SVD 를 사용하여 실제로 이미지 압축을 적용해보겠습니다.

2-1 : Diagonalization 의 정의가 다음과 같이 주어졌습니다.

Diagonalization 이란 정방행렬(A) 를 Eigenvalue, Eigenvector 를 통해서 대각행렬 (D) 를 만드는 것이며, 즉 $D = P^{-1} A P$ 를 통해서 대각행렬 (D) 를 찾는 것입니다.

조건들 : 1.) A 는 정방행렬 (Square Matrix) 이다. 2.) $A(n \times n)$ 는 n 개의 독립인 고유벡터를 가지고 있다.

- 1.) A 에 대한 고유벡터들을 찾으며, 이것을 각각 P_1, P_2, \dots, P_n 으로 놓는다
- 2.) $P = [P_1, P_2, \dots, P_n]$ 매트릭스를 만든다
- 3.) $P^{-1} A P$ 를 구하면 다음과 같은 형태가 나오게 된다

$$P^{-1} A P = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} = D$$

만약에 A 가 대칭 (Symmetric) 행렬이면 다음과 같은 꼴이 나오게 됩니다.

$$A = P D P^T$$

다음과 같은 정방행렬에 Diagonalization 을 적용시켜서 나오게 되는 대각행렬을 쓰시오.

a) $\begin{bmatrix} 6 & -1 \\ 2 & 3 \end{bmatrix}$ Eigenvalue = $(6-\lambda)(3-\lambda)+2 \quad \therefore \lambda = 4 \text{ or } 5$
 $= 20 - 9\lambda + \lambda^2 \quad \therefore D = \begin{bmatrix} 4 & 0 \\ 0 & 5 \end{bmatrix}$
 $= (\lambda - 4)(\lambda - 5)$

b) $\begin{bmatrix} 2 & 0 & 0 \\ 1 & 2 & 1 \\ -1 & 0 & 1 \end{bmatrix}$ Eigenvalue = $\lambda_1 = 1, \lambda_2 = 2, \lambda_3 = 2$
 $\therefore D = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$

c) $\begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}$ \therefore 자신은 대각행렬임
 $\therefore D = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}$

2-2 ✎ : SVD 의 정의가 다음과 같이 주어졌습니다.

SVD 란 Diagonalization 과는 달리 모든 행렬 (A) 에 대해서 사용이 가능합니다.

- 1.) $A^T A, A A^T$ 행렬들을 만듭니다. 이것은 항상 대칭 (Symmetric) 행렬이 됩니다.
- 2.) $A^T A = V D V^T, A A^T = U D' U^T$ 으로 대각화를 진행을 하고 나서 정규직교화까지 하게 된다면 U 와 V 를 얻게 됩니다.
- 3.) 여기에서 0 이 아닌 고유값들이 내림차순으로 나열된 것이 바로 D 가 되며, 이것은 바로 Σ 행렬의 대칭 원소들이 됩니다.
- 4.) 결국 $A = U \Sigma V^T$ 의 관계를 가지기 때문에 위에서 구한 U 와 V 를 대입시키면 되며 Σ 도 3.) 에서 구했던 걸로 대입을 하면 됩니다.

참고 자료 :

- <https://www.youtube.com/watch?v=rziHzFk5JyU>
- <https://www.youtube.com/watch?v=HeGdlgB8450> (해당 자료를 참고하여 문제를 풀어주세요.)
- https://angeloyeo.github.io/2019/08/01/SVD.html#google_vignette

다음과 같은 행렬에 SVD 를 적용하여 나오는 Σ 행렬을 구하시오.

$$\begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

then compute eigenvalues' square roots,
arrange them in descending order in the Σ

$$AA^T = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \lambda_1=2, \lambda_2=1$$

$$A^T A = \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \lambda_1=0, \lambda_2=1, \lambda_3=2$$

$$\Sigma = \begin{bmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

2-3 © : .ipynb 파일에서는 SVD (Singular Value Decomposition, 특이값-분해) 를 이미지 압축에 활용하는 예시를 보여주고 있습니다. 해당 코드를 확인한 후, 새로운 사진에 대해 원본에 비해서 적은 용량을 차지하면서도 원본에 대한 정보를 유지해주는 차원 수가 무엇인지 알아봅시오.

문제 3 모분산에 관한 추론

카이제곱 분포는 모집단의 모분산 추정에 유용하게 쓰이며, 정규분포에서의 랜덤표본에서 표본분산과 관계되는 분포입니다. 표준정규분포를 따르는 서로 독립인 확률변수 $Z_1, Z_2, Z_3, \dots, Z_k$ 가 있을 때, $V = Z_1^2 + Z_2^2 + Z_3^2 + \dots + Z_k^2 \Rightarrow V \sim$ 자유도가 k 인 χ^2 분포를 따른다고 할 수 있습니다. 대개 모분산에 관한 추론에 사용되며, 검정통계량으로 $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ 가 쓰입니다.

3-1 : 플라스틱 판을 제조하는 공장이 있다. 판 두께의 표준편차가 1.5mm 를 넘으면 공정 상에 이상이 있는 것으로 간주합니다. 오늘 아침 10 개의 판을 무작위 추출하여 두께를 측정한 결과가 다음과 같았습니다.

{226, 228, 226, 225, 232, 228, 227, 229, 225, 230}

해당 판 두께의 분포가 정규분포를 따른다고 할 때, 공정에 이상이 있는지를 검정하세요.

a) 귀무가설과 대립가설을 설정하시오.

H_0 = 귀무가설 : 표준편차가 1.5mm를 넘어가지 않았으며, 공정에 이상이 없다.

H_1 대립가설 : 표준편차가 1.5mm를 넘었으며, 공정에 이상이 있다.

b) 유의수준 5%에서의 가설검정을 수행하고 판 두께의 분산에 대한 90% 신뢰구간을 구하시오.

어떤 검정통계량이 어떤 분포를 따르는지, 언제 귀무가설을 기각하는지 정해야 합니다.

mean value = 227.6

variance ≈ 5.16 , standard deviation ≈ 2.27

∵ 검정통계량 = 표준편차

∴ χ^2 통계를 사용해서 p-value를 구함

$$\chi^2 = \frac{(10-1) \cdot 2.27^2}{1.5^2} = 20.6116$$

$$df = \text{자유도} = \text{표본수} - 1 = 9$$

cdf를 통해 p-value를 계산함

$$\therefore p\text{-value} \approx 0.0145 < 0.05$$

∴ 귀무가설 기각됨, 공정 이상 존재함

90% confidence interval

$$= \left(\frac{df \cdot s^2}{\chi^2_{0.95,9}}, \frac{df \cdot s^2}{\chi^2_{0.05,9}} \right)$$

$$= (2.74, 13.95)$$

문제 4 통계적 방법론

t 검정은 모집단이 정규분포를 따르지만 모표준편차를 모를 때, 모평균에 대한 가설검정 방법입니다. 대개 두 집단의 모평균이 서로 차이가 있는지 파악하고자 할 때 사용하며, 표본평균의 차이와 표준편차의 비율을 확인하여 통계적 결론을 도출합니다. ANOVA Test의 경우 집단이 2개보다 많은 경우 모평균에 차이가 있는지 파악하고자 할 때 사용되며, 이것은 코드로만 살펴보겠습니다.

4-1 ✎ : 어떤 학우가 DSL 학회원(동문 포함)의 평균 키가 DSL 학회원이 아닌 사람의 평균 키보다 크다고 주장하여, 실제로 그러한지 통계적 검정을 수행하려고 합니다. 며칠간 표본을 수집한 결과 다음과 같은 값을 얻었습니다.

표본 수: 총 250 명, 각 125 명

측정에 응한 DSL 학회원들의 평균 키 : 173.5cm / 표준편차 : 7.05cm

측정에 응한, DSL 학회원이 아닌 사람들의 평균 키 : 171.4cm / 표준편차 : 7.05cm

a) ✎ 귀무가설과 대립가설을 설정하시오.

H_0 - 귀무가설: 사람 키와 DSL 학회원인 여부를 무관하다.

H_1 - 대립가설: DSL 학회원의 평균 키가 DSL 아닌 사람의 키를 보다 더 크다

b) ✎ 유의수준 5%에서의 가설검정을 수행하고 결론을 도출하시오. (단, 키는 정규분포를 따르며 각 집단의 분산은 같다고 가정한다.)

👉 통계학입문(3 판) 7 장 참고

👉 어떤 검정통계량이 어떤 분포를 따르는지, 언제 귀무가설을 기각하는지 정해야 합니다.

이번 가설은 평균치로 위한 검정이며, t-value를 통해 p-value를 찾겠다.

코드 실행해서 받은 결과 : t-value ≈ -2.41 , p-value ≈ 0.0174

👉 기각, 학회원의 키를 더 크다

4-2 © : 한 학우가 이번에는 각 학회의 평균 키가 똑같다는 주장을 하였습니다. 해당 학우가 제공한 ESC 학회의 학회원별 키 데이터를 활용해 가설검정을 진행하고자 합니다.

a) ✎ 귀무가설과 대립가설을 설정하시오.

H_0 - 귀무가설: DSL 학회원의 키와 ESC 학회원의 키의 평균치를 같아

H_1 - 대립가설: DSL 학회원의 키와 ESC 학회원의 키의 평균치를 다르다

b) © 파이썬의 scipy.stats 을 활용해서 유의수준 5%에서의 가설검정을 수행하고 결론을 도출하시오. 결론은 .ipynb 파일에 쓰셔도 괜찮습니다.

👉 One-way Anova Test 를 활용해서 사용하는 문제입니다.

👉 활용해야 될 함수는 scipy.stats.f_oneway 입니다.

문제 5

© Numpy + Pandas 활용

기초과제.ipynb 파일에 제공된 문제를 참고하여 수행하기 바랍니다.

Reference

- Introduction to Mathematical Statistics(8 판, Hogg et.al)
- 23-2 기초과제 1 (9 기 이성균)
- 24-1 기초과제 1 (10 기 신재우)

Data Science Lab

담당자 : 11 기 김현진, 11 기 김정우

Rlaguswls186790@yonsei.ac.kr

kjungwoo@yonsei.ac.kr